



PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO
PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS E ANALYTICS

MVP — ENGENHARIA DE DADOS

**Pipeline Analítico e Diagnóstico Operacional de Sistemas Mecânicos no Parque Eólico de
Kelmarsh**

Trabalho apresentado como requisito parcial da
Sprint de Engenharia de Dados do curso de Pós-
Graduação em Ciência de Dados e Analytics da
PUC-Rio.

Aluno: João Victor Amaral dos Santos

Matrícula: 4052025002072

Rio de Janeiro
2026

RESUMO

Este trabalho apresenta o desenvolvimento de um pipeline de dados na nuvem para a análise operacional do Parque Eólico de Kelmarsh, no Reino Unido, composto por seis turbinas Senvion MM92 de 2.050 kW. A partir dos dados públicos de telemetria SCADA, registrados em intervalos de 10 minutos, e do log de eventos operacionais referentes ao ano de 2018 (PLUMLEY, 2022), foi construída no Databricks Free Edition uma arquitetura medalhão com as camadas Bronze, Silver e Gold, persistidas em Delta Lake e governadas pelo Unity Catalog. A camada Gold foi modelada em esquema estrela, com granularidade de uma leitura por turbina a cada 10 minutos, e a reconciliação entre leituras e eventos de parada foi feita por junção por intervalo, preservando as 315.360 leituras da base. A auditoria de qualidade avaliou completude, unicidade, validade de domínio e cobertura temporal, identificando leituras de rotação negativa do gerador, tratadas em uma tabela curada, e uma queda sistêmica de preenchimento em outubro de 2018. As análises em SQL mostraram que a curva de potência do parque reproduz a do fabricante e que a turbina 5 produz cerca de 16% menos energia em vento forte, sem maior indisponibilidade. A investigação por eliminação de hipóteses apontou como causa-raiz provável um controle de pitch descalibrado, com ângulo médio quase duas vezes superior ao das demais turbinas. Conclui-se que o pipeline fornece uma base confiável para o diagnóstico de desempenho e para a priorização da manutenção.

Palavras-chave: engenharia de dados; energia eólica; SCADA; arquitetura medalhão; SQL; Databricks.

SUMÁRIO

1. Contexto de Negócio e Perguntas	4
1.1 Problema e objetivo	4
1.2 Perguntas de negócio	5
1.3 Fonte, coleta e licença dos dados	6
1.4 Estrutura dos dados brutos	7
2. Carga dos Dados	8
3. Modelagem e Catálogo de Dados.....	11
3.1 Modelo dimensional.....	11
3.2 Catálogo de Dados	13
4. Pipeline de Dados	14
4.1 Silver	16
4.2 Gold e reconciliação.....	18
4.3 Tecnologias.....	19
5. Qualidade de Dados	19
5.1 Completude	19
5.2 Eventos sem término.....	20
5.3 Unicidade	21
5.4 Validade de domínio	21
5.5 Cobertura temporal.....	23
6. Análise de Dados	23
6.1 Pergunta 1 — Curva de potência	23
6.2 Pergunta 2 — Disponibilidade.....	25
6.3 Pergunta 3 — Temperatura × operação e causa-raiz	27
6.4 Pergunta 4 — Eventos no tempo	29
6.5 Pergunta 5 — Qualidade e governança	30
6.6 Síntese	31
7. Autoavaliação	31
Referências	33


1. Contexto de Negócio e Perguntas

1.1 Problema e objetivo

A manutenção preditiva e a análise de desempenho de ativos rotativos dependem do monitoramento contínuo de parâmetros de operação, de modo que falhas e perdas de eficiência sejam identificadas antes de provocarem paradas e queda de produção. Em parques eólicos, esse monitoramento é feito por telemetria conhecida como SCADA (Supervisory Control and Data Acquisition, ou Supervisão, Controle e Aquisição de Dados), que registra, dentro de um intervalo de tempo, as leituras dos sensores de cada turbina. O volume gerado é grande, e, em estado bruto, esses dados não respondem diretamente a perguntas de negócio.

O objetivo deste MVP é construir um pipeline de dados na nuvem capaz de transformar a telemetria SCADA e o log de eventos operacionais do Parque Eólico de Kelmarsh, no Reino Unido, referentes ao ano de 2018, em uma camada analítica modelada em esquema estrela, para responder a perguntas de performance e manutenção das turbinas.

Figura 1 – Localização e layout do parque eólico de Kelmarsh.



Fonte: A short-term... (2025).

Figura 2 – Parque eólico de Kelmarsh.



Fonte: Blue Energy ([20--]).

A escolha do dataset combina relevância técnica e desafios reais de engenharia de dados. As turbinas reúnem sistemas eletromecânicos, como pás, multiplicadora, gerador e mancais, e o SCADA reflete essa complexidade: são 299 colunas e 52.560 leituras por turbina no ano, ou 315.360 registros no parque. Somada à necessidade de combinar duas fontes distintas, a telemetria contínua e o log de eventos, essa escala exige as etapas típicas da engenharia de dados (REIS; HOUSLEY, 2022): ingestão, padronização de tipos, auditoria de qualidade, reconciliação entre fontes e modelagem dimensional.

A formação do autor em engenharia mecânica permitiu interpretar os sinais dos sensores à luz do funcionamento da máquina.

O código-fonte, os notebooks e o catálogo de dados estão disponíveis no repositório GitHub: <https://github.com/eng-jvamaral/MVP-PUCRJ-DTE/tree/main/PUCRJ-MVP-DTE-EOLENG>

1.2 Perguntas de negócio

A partir dos dados tratados no pipeline, o MVP busca responder às seguintes perguntas de negócio:

- I. Curva de potência: como a potência média se comporta em função da velocidade do vento? A curva observada corresponde à do fabricante? Alguma turbina fica sistematicamente abaixo das demais (subperformance)?
- II. Disponibilidade: qual a fração do tempo em que cada turbina permanece em operação normal ou parada? Quais turbinas perdem mais tempo produtivo?
- III. Temperatura $\times$ operação: como as temperaturas de mancais, gerador e multiplicadora variam com a carga e o vento? Há anomalias que ajudem a explicar perdas de desempenho?
- IV. Eventos no tempo: como os eventos operacionais se distribuem por tipo? Quais são os mais frequentes e quais custam mais tempo?
- V. Qualidade e governança: qual é a cobertura de cada sinal ao longo do tempo, o percentual de nulos por sensor e a ocorrência de leituras implausíveis, como potência negativa ou vento fora de faixa?

As três primeiras perguntas tratam do desempenho e da disponibilidade das turbinas; a quarta, do impacto operacional dos eventos registrados; e a quinta, da qualidade e governança dos dados, condição para que as demais respostas sejam confiáveis. Cada pergunta é respondida na subseção correspondente da Seção 6 (6.1 a 6.5).

1.3 Fonte, coleta e licença dos dados

Os dados utilizados provêm do conjunto Kelmarsh Wind Farm Data, publicado no repositório Zenodo (DOI 10.5281/zenodo.5841834) por Plumley (2022) e disponibilizado pela Cubico Sustainable Investments Ltd., proprietária do parque. O parque é composto por seis turbinas Senvion MM92, de 2.050 kW cada, e o conjunto reúne, para cada turbina, a telemetria SCADA agregada em intervalos de 10 minutos, o log de eventos de status e os dados cadastrais das máquinas.

O conjunto é distribuído sob a licença Creative Commons Atribuição 4.0 Internacional (CC BY 4.0), que permite o uso, a redistribuição e a adaptação dos dados, inclusive para fins comerciais, desde que a fonte seja devidamente atribuída. Neste trabalho, a atribuição é feita pela citação da fonte no texto e pela referência completa ao final do documento.

O escopo foi limitado ao ano de 2018, primeiro ano completo com estatísticas de vento disponíveis, já que esses sinais passam a ser registrados apenas a partir de setembro de 2017. Os arquivos foram baixados manualmente do Zenodo e enviados para um Volume do Databricks.

1.4 Estrutura dos dados brutos

O conjunto bruto é formado por quatro tipos de arquivo CSV, descritos na Tabela 1. Para cada uma das seis turbinas há um arquivo de telemetria e um de eventos referentes a 2018, complementados por dois arquivos de referência comuns ao parque.

Tabela 1 – Arquivos brutos do conjunto Kelmarsh utilizados no MVP.


Arquivo	Qtd.	Dimensões	Conteúdo
Turbine_Data	6	52.560 linhas × 299 colunas (por arquivo)	Telemetria SCADA em intervalos de 10 minutos
Status	6	~9 a 16 mil eventos × 9 colunas (69.963 no total)	Log de eventos de status, com início, fim, tipo e mensagem
WT_static	1	6 linhas × 14 colunas	Cadastro das turbinas: modelo, potência nominal, altura do cubo e coordenadas
dataSignalMapping	1	—	Dicionário dos sinais do SCADA (referência)

Fonte: elaborado pelo autor com base em Plumley (2022).

A inspeção inicial dos arquivos revelou particularidades do formato bruto que condicionaram as decisões de ingestão descritas na Seção 2:

- a) os arquivos de telemetria e de status trazem 9 linhas de metadados antes do cabeçalho;
- b) o identificador da turbina não existe como coluna e aparece apenas no nome do arquivo;
- c) nos eventos instantâneos, o campo Timestamp end vem preenchido com o caractere "-" em vez de ficar vazio; e
- d) o arquivo estático começa com o marcador BOM (\uffff), que contamina o nome da primeira coluna.

Figura 3 – Inspeção inicial dos arquivos brutos (colunas do SCADA e do log de status).




Fonte: elaborado pelo autor (2026).

2. Carga dos Dados

Os dados foram obtidos manualmente no repositório Zenodo (PLUMLEY, 2022), conforme descrito na Seção 1.3, totalizando 14 arquivos CSV: seis de telemetria SCADA (Turbine_Data) e seis de log de eventos de status (Status), um de cada tipo por turbina, além de dois arquivos de referência comuns ao parque (WT_static e dataSignalMapping).


Para armazená-los, foi criado o Volume `kelmarsh_raw` no esquema `workspace.default` do Unity Catalog, organizado em dois diretórios: `ref`, com os arquivos de referência, e `scada_2018`, com os arquivos das turbinas (Figuras 4 a 6). Os arquivos foram enviados sem qualquer alteração, de modo que o Volume funciona como zona de pouso (landing zone) do pipeline e preserva uma cópia fiel da fonte original.

Figura 4 – Arquivos de referência no diretório ref do Volume.




Fonte: elaborado pelo autor (2026).

Figura 5 – Upload dos dados das turbinas no Volume.



Fonte: elaborado pelo autor (2026).

Figura 6 – Dados das turbinas no diretório scada_2018 do Volume.



Fonte: elaborado pelo autor (2026).

Concluído o upload, a camada Bronze foi implementada no notebook 01_bronze, disponível no repositório do projeto (notebooks/01_bronze). O objetivo dessa camada é converter os CSVs em tabelas Delta com a menor intervenção possível: são corrigidos apenas os obstáculos de formato identificados na Seção 1.4, que impediriam a leitura dos arquivos, e toda interpretação do conteúdo fica para a camada Silver. Com esse princípio, foram tomadas as decisões descritas a seguir.

Leitura dos arquivos: Os CSVs foram lidos com a biblioteca pandas, descartando as nove linhas de metadados que antecedem o cabeçalho e forçando todas as colunas para o tipo texto (dtype=str). Manter os valores como string evita que a inferência automática de tipos altere ou descarte informações, como o caractere "-" usado nos eventos instantâneos, e preserva o dado exatamente como veio da fonte. A conversão para os tipos adequados é feita na camada Silver.

Padronização dos nomes de colunas: Os cabeçalhos originais contêm espaços e caracteres especiais incompatíveis com os nomes de colunas aceitos pelo Delta Lake. Por isso, foi criada a função `limpar_nome`, que higieniza os nomes das colunas sem alterar os valores registrados.

Identificação da turbina e linhagem: Como o identificador da turbina consta apenas no nome do arquivo, a função `pegar_turbina` o extrai e o grava em uma coluna própria, permitindo distinguir as leituras de cada máquina depois da consolidação. Além disso, a coluna

arquivo_origem registra o arquivo de onde cada linha foi lida, o que garante a rastreabilidade (linhagem) de todos os registros até a fonte.

Consolidação e gravação: Cada DataFrame pandas foi convertido em DataFrame Spark (PySpark) e gravado em tabela Delta. O primeiro arquivo de cada tipo é gravado no modo overwrite e os demais no modo append, o que reúne as seis turbinas em uma única tabela e torna a carga idempotente (KLEPPMANN, 2017): ao reexecutar o notebook, a tabela é recriada do zero, sem duplicar registros. A opção mergeSchema foi habilitada para acomodar eventuais diferenças de colunas entre os arquivos.

Como resultado, a camada Bronze é composta por duas tabelas: bronze_scada, com 315.360 leituras (6 turbinas $\times$ 52.560 intervalos de 10 minutos), e bronze_status, com 69.963 eventos. As contagens coincidem com as dos arquivos de origem (Tabela 1), o que confirma que a ingestão ocorreu sem perdas nem duplicações.

3. Modelagem e Catálogo de Dados

3.1 Modelo dimensional

A camada analítica foi modelada em esquema estrela (KIMBALL; ROSS, 2013), com uma tabela fato central e tabelas de dimensão que fornecem o contexto de cada registro. O grão foi definido como uma linha por turbina a cada 10 minutos, a resolução original do SCADA, o que preserva o nível máximo de detalhe da fonte e permite agregações por qualquer recorte de tempo ou de turbina.

A tabela fato gold_fato_scada concentra as medições operacionais e referencia três dimensões: gold_dim_turbina, com os atributos cadastrais de cada máquina (localização, potência nominal, diâmetro do rotor e altura do cubo); gold_dim_tempo, que decompõe cada instante em ano, mês, dia, hora, minuto e dia da semana; e gold_dim_status, que descreve o estado operacional atribuído a cada leitura (Figura 7).

Das 299 colunas do SCADA, foram mantidas 13 medidas, selecionadas por responderem às perguntas de negócio:


- a) velocidade do vento (média, desvio-padrão, mínimo e máximo);
- b) potência ativa;
- c) rotação do rotor;
- d) rotação do gerador;
- e) ângulo de pitch da pá;

- f) temperaturas dos mancais dianteiro e traseiro;
- g) temperatura do óleo da multiplicadora (caixa de engrenagens);
- h) temperatura do mancal dianteiro do gerador;
- i) temperatura ambiente.

As unidades de medida foram mantidas no nome das colunas, como nos dados brutos. Foram excluídas as estatísticas derivadas (mínimo, máximo e desvio-padrão) dos demais sinais, os sensores redundantes de vento e de temperatura e a família de colunas de potência teórica, por não contribuírem para as perguntas propostas. A redução é, portanto, uma decisão de modelagem, e não uma limitação da base.

O atributo `status_id` é um indicador binário obtido pela reconciliação com os eventos do tipo Stop (Seção 4.2): 0 indica operação normal e 1, turbina parada. Os eventos Warning e Communication, em geral alertas com a turbina ainda em operação, ficaram fora desta primeira versão e são classificados como 0; sua inclusão é discutida como trabalho futuro. Os registros de tempo são mantidos em UTC, como na fonte.

Figura 7 – Diagrama de relacionamento (ER) do modelo.



Fonte: elaborado pelo autor (2026).

3.2 Catálogo de Dados

O catálogo de dados da camada Gold descreve, para cada tabela do esquema estrela, suas colunas, tipos, significado, unidade, origem na camada anterior e um exemplo real (Figuras 8 a 11).

Esses metadados também foram registrados como comentários de tabela e de coluna no Unity Catalog do Databricks, de modo que a documentação acompanha os dados na própria plataforma.

Figura 8 – Catálogo de dados da tabela fato gold_fato_scada.

Column	Type	Comment
turbina_id	int	FK -> gold_dim_turbina
tempo_id	timestamp	FK -> gold_dim_tempo, Instante da leitura (UTC)
status_id	int	FK -> gold_dim_status, 0 Normal, 1 Stop (range join com silver_status)
gold_fato_scada	double	Velocidade média do vento (m/s)
	double	Desvio-padrão do vento no intervalo (m/s)
	double	Vento mínimo no intervalo (m/s)
	double	Vento máximo no intervalo (m/s)
power_kw	double	Potência ativa média (kW), Nominal 2050 kW
rotor_speed_rpm	double	Rotação do rotor (rpm), Faixa do fabricante 7,8-15
generator_rpm	double	Rotação do gerador (rpm), Faixa do fabricante 900-1800
blade_pitch_deg	double	Ângulo de pitch da pá A (graus, convenção circular 0-360)
front_bearing_temp_c	double	Temperatura do mancal dianteiro (°C)

Fonte: elaborado pelo autor (2026).

Figura 9 – Catálogo de dados da dimensão gold_dim_turbina.

Column	Type	Comment
turbina_id	int	PK, Identificador da turbina (1-6)
nome	string	Nome da turbina
latitude	double	Latitude (graus)
longitude	double	Longitude (graus)
potencia_nominal_kw	int	Potência nominal (kW)
diametro_rotor_m	double	Diâmetro do rotor (m)
altura_cubo_m	double	Altura do cubo (m): 68,5 nas turbinas 3 e 6; 78,5 nas demais

Fonte: elaborado pelo autor (2026).

Figura 10 – Catálogo de dados da dimensão gold_dim_tempo.

Search data, notebooks, recents, and more... CTRL + P

Catalog Explorer > workspace > default >

gold_dim_tempo ☆

Overview Sample Data Details Permissions Policies History Lineage Insights Quality

Description ✎
Dimensão tempo: 52.560 instantes de 10 min de 2018, em UTC.

Filter columns...

Column	Type	Comment
tempo_id	timestamp	PK. Instante de 10 min (UTC)
data	date	Data sem hora
ano	int	Ano
mes	int	Mês (1-12)
dia	int	Dia do mês
hora	int	Hora (0-23)
minuto	int	Minuto (0, 10, 20, 30, 40, 50)
dia_semana	string	Dia da semana (em inglês)

About this table

Owner joaovictor.as.eng@gmail.com ✎

Type Managed ⓘ

Data source Delta

Popularity all

Quality

Not enabled

Data Quality Monitoring is not enabled for this table

Enable

Policies ⓘ

New policy

Tags

Add tags

Row filter ⓘ

Fonte: elaborado pelo autor (2026).

Figura 11 – Catálogo de dados da dimensão gold_dim_status.

Search data, notebooks, recents, and more... CTRL + P

Catalog Explorer > workspace > default >

gold_dim_status ☆

Overview Sample Data Details Permissions Policies History Lineage Insights Quality

Description ✎
Dimensão status operacional: 0 = Normal, 1 = Stop.

Filter columns...

Column	Type	Comment
status_id	bigint	PK. 0 = Normal, 1 = Stop
status	string	Nome do status
descricao	string	Descrição do status

About this table

Owner joaovictor.as.eng@gmail.com ✎

Type Managed ⓘ

Data source Delta

Popularity all

Quality

Not enabled

Data Quality Monitoring is not enabled for this table

Enable

Policies ⓘ

New policy

Tags

Add tags

Row filter ⓘ

Fonte: elaborado pelo autor (2026).

A versão completa do catálogo, em formato Markdown, está disponível no repositório do projeto no GitHub (docs/catalogo.md).

4. Pipeline de Dados

O pipeline ETL (extração, transformação e carga) segue a arquitetura medalhão, com as camadas Bronze, Silver e Gold, padrão recomendado pelo Databricks (DATABRICKS, 2026) em que cada camada eleva o grau de tratamento e de confiabilidade dos dados.

O processo foi dividido em cinco notebooks, um por etapa. A separação permite reexecutar cada camada de forma independente, por exemplo reprocessar a Silver sem repetir a ingestão dos arquivos brutos, e facilita a manutenção do código. Os notebooks se comunicam

exclusivamente pelas tabelas Delta persistidas no Unity Catalog, sem depender de variáveis em memória. A Tabela 2 resume a organização adotada; os scripts e suas versões em HTML, com as saídas de execução, estão na pasta notebooks/ do repositório.

Tabela 2 – Organização do pipeline por notebook.

Notebook	Camada	Responsabilidade	Tabelas produzidas
01_bronze	Bronze	Ingestão fiel dos CSVs do Volume, todos os campos como texto, com identificação da turbina e do arquivo de origem	bronze_scada, bronze_status
02_silver	Silver	Tipagem, padronização de nomes e chaves, tratamento de valores inválidos e seleção das medidas	silver_scada, silver_status, silver_turbina
03_gold	Gold	Construção do esquema estrela e reconciliação das leituras com os eventos de parada	gold_dim_turbina, gold_dim_tempo, gold_dim_status, gold_fato_scada
04_qualidade	Gold (curadoria)	Auditoria de completude, unicidade e domínio; aplicação das regras de curadoria	gold_fato_scada_curado
05_analises	Consumo	Consultas SQL e visualizações que respondem às perguntas de negócio	— (sem persistência)

Fonte: elaborado pelo autor (2026).


As Figuras 12 a 14 evidenciam a persistência das tabelas no Unity Catalog, a leitura da camada Bronze e os notebooks no workspace. As evidências das camadas Silver e Gold são apresentadas nas Seções 4.1 e 4.2.

Figura 12 – Tabelas persistidas no Unity Catalog.

Name	Owner	Created at	Popularity	Comment
bronze_scada	joavictor.as.eng@gmail.com	Aug 29, 2026, 05:09 PM	...	
bronze_status	joavictor.as.eng@gmail.com	Aug 29, 2026, 06:04 PM	...	
gold_dim_turbina	joavictor.as.eng@gmail.com	Sep 07, 2026, 03:15 PM	...	Dimensão status operacional...
gold_dim_tempo	joavictor.as.eng@gmail.com	Sep 07, 2026, 03:08 PM	...	Dimensão tempo 52.560 m...
gold_dim_status	joavictor.as.eng@gmail.com	Sep 07, 2026, 12:01 PM	...	Dimensão turbina: cadastro...
gold_fato_scada	joavictor.as.eng@gmail.com	Sep 07, 2026, 02:28 PM	...	Fato SCADA do parque eólico...
gold_fato_scada_curado	joavictor.as.eng@gmail.com	Sep 12, 2026, 04:54 PM	...	Versão curada do gold_fato...
gold_turbina	joavictor.as.eng@gmail.com	Sep 07, 2026, 11:58 AM	...	
silver_scada	joavictor.as.eng@gmail.com	Sep 07, 2026, 09:18 AM	...	
silver_status	joavictor.as.eng@gmail.com	Sep 07, 2026, 09:54 AM	...	
silver_turbina	joavictor.as.eng@gmail.com	Sep 07, 2026, 10:43 AM	...	


Fonte: elaborado pelo autor (2026).

Figura 13 – Leitura da bronze_scada persistida e seleção das colunas-medida.



Fonte: elaborado pelo autor (2026).

Figura 14 – Notebooks do pipeline no workspace do Databricks.



Fonte: elaborado pelo autor (2026).

4.1 Silver

A camada Silver (notebook 02_silver) converte as tabelas Bronze, armazenadas como texto, em tabelas tipadas e padronizadas, prontas para a modelagem. A conversão foi orientada por um mapa de colunas que associa a cada campo o nome de origem, o nome final e o tipo de destino (double para as medidas e timestamp para as datas). Em uma única etapa, o mapa aplica


a seleção das 13 medidas definidas na Seção 3.1, a tipagem e a renomeação, eliminando caracteres como “” herdados dos cabeçalhos originais (Figura 15).

Valores inválidos: no log de status, o caractere “-” usado nos eventos instantâneos impedia a conversão para timestamp e interrompia a execução. A conversão passou a ser feita com `try_cast`, que transforma valores não conversíveis em nulo sem interromper o processamento. O significado desses nulos é tratado na Seção 5.2.

Cadastro das turbinas: o arquivo WT_static foi lido com a codificação utf-8-sig, que remove o marcador BOM, e o identificador numérico da turbina foi extraído do campo de título (“Kelmarsh 1” → 1), padronizando a chave `turbina_id` usada em todas as tabelas (Figura 16).

A camada Silver resulta em três tabelas: `silver_scada` (315.360 leituras), `silver_status` (69.963 eventos, com início e fim tipados) e `silver_turbina` (6 turbinas).

Figura 15 – Esquema tipado da `silver_scada` e amostra dos dados.



```

> silver: pyspark.sql.connect.dataframe.DataFrame = [turbina_id: integer, tempo: timestamp
... 13 more fields]

root
|-- turbina_id: integer (nullable = true)
|-- tempo: timestamp (nullable = true)
|-- wind_speed_m_s: double (nullable = true)
|-- wind_speed_std_m_s: double (nullable = true)
|-- wind_speed_min_m_s: double (nullable = true)
|-- wind_speed_max_m_s: double (nullable = true)
|-- power_kw: double (nullable = true)
|-- rotor_speed_rpm: double (nullable = true)
|-- generator_rpm: double (nullable = true)
|-- blade_pitch_a_deg: double (nullable = true)
|-- front_bearing_temp_c: double (nullable = true)
|-- rear_bearing_temp_c: double (nullable = true)
|-- gear_oil_temp_c: double (nullable = true)
|-- generator_bearing_front_temp_c: double (nullable = true)
|-- nacelle_ambient_temp_c: double (nullable = true)


```

	1.2 turbina_id	tempo	1.2 wind_speed_m_s	1.2
1	1	2018-05-17T21:00:00.000+00:...	2.9048526287078857	
2	1	2018-05-17T21:10:00.000+00:...	3.0757017135620117	
3	1	2018-05-17T21:20:00.000+00:...	3.4196462631225586	
4	1	2018-05-17T21:30:00.000+00:...	3.287592649459839	
5	1	2018-05-17T21:40:00.000+00:...	3.2271682866171112	

linhas: 315360 | power_kw nulos: 11002 | %: 3.49

Fonte: elaborado pelo autor (2026).

Figura 16 – Tabela silver_turbina persistida, com as seis turbinas tipadas.



```

# vira dataframe Spark pra trabalhar
sdf = spark.createDataFrame(df_stc)

silver_turbina = sdf.select(
    # turbina_id = último pedaço do "title" (Kelmarsh 1 -> 1)
    F.expr("try_cast(split(title, ' ')[1] AS int)").alias("turbina_id"),
    F.col("title").alias("nome"),
    F.col("latitude").cast("double").alias("latitude"),
    F.col("longitude").cast("double").alias("longitude"),
    F.col("rated_power_kw").cast("int").alias("potencia_nominal_kw"),
    F.col("rotor_diameter_m").cast("double").alias("diametro_rotor_m"),
    F.col("hub_height_m").cast("double").alias("altura_cubo_m"),
)

(silver_turbina.write.mode("overwrite")
  .option("overwriteSchema", "true")
  .saveAsTable(f"{CATALOGO}.{SCHEMA}.silver_turbina"))

display(silver_turbina.orderBy("turbina_id"))

```

2 dataframes: sdf, silver_turbina

turbina_id	nome	latitude	longitude	potencia_nominal_kw	diametro_rotor_m	altura_cubo_m
1	Kelmarsh 1	52.400604	-0.947133	2050	92	78.5
2	Kelmarsh 2	52.402551	-0.949527	2050	92	78.5
3	Kelmarsh 3	52.403834	-0.94419	2050	92	68.5
4	Kelmarsh 4	52.398781	-0.94115	2050	92	78.5
5	Kelmarsh 5	52.402308	-0.940537	2050	92	78.5
6	Kelmarsh 6	52.400687	-0.936093	2050	92	68.5

6 rows 5.282s runtime

Fonte: elaborado pelo autor (2026).

4.2 Gold e reconciliação


O notebook 03_gold constrói o esquema estrela descrito na Seção 3. A gold_dim_turbina deriva diretamente da silver_turbina; a gold_dim_tempo decompõe os 52.560 instantes distintos do SCADA em ano, mês, dia, hora, minuto e dia da semana; e a gold_dim_status registra os dois estados operacionais do modelo (0 = Normal, 1 = Stop).

A etapa central é a reconciliação entre as duas fontes, que não compartilham uma chave comum: as leituras SCADA são instantes de 10 minutos, enquanto os eventos de parada são intervalos com início e fim. A associação foi feita por uma junção por intervalo (range join): cada leitura é ligada ao evento Stop da mesma turbina cuja janela a contém, segundo a condição $\text{tempo_inicio} \leq \text{tempo} < \text{tempo_fim}$. O intervalo é fechado no início e aberto no fim para que um instante não pertença a dois eventos consecutivos.

Foi utilizada uma junção à esquerda (LEFT JOIN), para que todas as leituras sejam preservadas: as que coincidem com uma janela de parada recebem status_id = 1, e as demais, status_id = 0. Apenas eventos Stop com início e fim registrados participam da junção.

A validação confirmou a integridade da operação (Figura 17): a gold_fato_scada mantém as 315.360 leituras da origem, sem perdas nem duplicações, das quais 302.071 (95,8%) em operação normal e 13.289 (4,2%) em parada.

Figura 17 – Validação da reconciliação na gold_fato_scada: total de linhas e distribuição Normal × Stop.



Fonte: elaborado pelo autor (2026).

4.3 Tecnologias

O pipeline foi desenvolvido no Databricks Free Edition, plataforma baseada na arquitetura lakehouse (ARMBRUST et al., 2021), com computação serverless. Os dados são persistidos em Delta Lake, formato com transações ACID e versionamento (ARMBRUST et al., 2020), e governados pelo Unity Catalog, que centraliza o Volume de arquivos brutos, as tabelas das três camadas e os metadados de descrição. No pipeline foram utilizados pandas, na leitura dos CSVs com linhas de metadados, e PySpark, interface Python do Apache Spark (ZAHARIA et al., 2016), nas transformações; as análises da Seção 6 foram escritas em SQL. Os notebooks e suas versões em HTML estão na pasta notebooks/ do repositório do projeto.

5. Qualidade de Dados


A qualidade dos dados foi auditada no notebook 04_qualidade, sobre a gold_fato_scada, e em validações pontuais na camada Silver. Para cada problema, descrevem-se a detecção, a investigação e o tratamento adotado, com base em dimensões usuais de qualidade de dados, como completude, unicidade e validade (DAMA INTERNATIONAL, 2017).

5.1 Completude

Deteção: as medidas apresentam cerca de 3,5% de valores nulos (11.002 leituras), e a velocidade do vento, 3,61% (Figura 18). **Investigação:** a proporção é praticamente idêntica

entre as colunas porque, quando a turbina está parada ou sem comunicação, todos os sensores deixam de reportar ao mesmo tempo; os nulos ocorrem, portanto, em bloco, nas mesmas linhas. A pequena diferença do vento corresponde a falhas isoladas do anemômetro. **Tratamento:** os nulos foram mantidos. Imputar valores criaria medições para períodos em que a turbina não operava, e as funções de agregação do SQL já os desconsideram.

Figura 18 – Percentual de valores nulos por coluna da gold_fato_scada.



Fonte: elaborado pelo autor (2026).

5.2 Eventos sem término

Deteção: 60.301 dos 69.963 eventos do log não possuem tempo_fim (Figura 19).

Investigação: todos pertencem à categoria Informational, que registra marcos instantâneos, como “System OK” ou “Brake program”, e por natureza não têm duração. Os eventos de duração, Stop (733), Warning (524) e Communication (98), têm 100% das janelas completas.

Tratamento: os eventos sem término foram mantidos na silver_status e excluídos apenas da reconciliação (gold), que exige uma janela definida. Não há valor a corrigir.

Figura 19 – Eventos por status e quantidade sem término registrado.



```

silver_st = spark.table(f"{CATALOGO}.{SCHEMA}.silver_status")

display(
  silver_st.groupBy("status")
    .agg(
      F.count("*").alias("total"),
      F.sum(F.when(F.col("tempo_fin").isNull(), 1).otherwise(0)).alias("sem_fin")
    )
    .orderBy(F.desc("total"))
)

```

#	status	total	sem_fin
1	Informational	66608	60301
2	Stop	733	0
3	Warning	524	0
4	Communication	98	0

Fonte: elaborado pelo autor (2026).

5.3 Unicidade

A chave composta (turbina_id, tempo_id) da gold_fato_scada foi verificada por agrupamento, sem nenhuma ocorrência duplicada. O resultado confirma que o grão do modelo, uma linha por turbina a cada 10 minutos, é respeitado, e que a junção por intervalo da Seção 4.2 não gerou duplicações por sobreposição de janelas.

5.4 Validade de domínio


Para cada medida foi definida uma faixa fisicamente plausível, com base na ficha técnica da Senvion MM92 (SENVION, [20--]): velocidade de partida de 3 m/s, velocidade de corte de 24 m/s, rotação do rotor de 7,8 a 15 rpm e rotação nominal do gerador de 900 a 1.800 rpm. A auditoria contou as leituras fora dessas faixas (Figura 20), e duas medidas exigiram investigação.

Ângulo de pitch: valores de até 356° pareciam indicar erro, mas o sistema de pitch registra o ângulo em convenção circular de 0° a 360°: 356° equivale a -4°, isto é, pá voltada para o vento. Com a faixa ajustada a essa convenção, não há leituras inválidas, e nenhum tratamento foi aplicado.

Rotação negativa do gerador: 2.031 leituras (0,6%) apresentaram valores negativos, com mínimo de -589 rpm, fisicamente impossíveis. A investigação reuniu três evidências independentes (Figura 21): 100% dessas leituras têm potência nula ou negativa, 100% têm rotor abaixo de 0,5 rpm e 421 estão dentro de janelas de parada registradas. Muitas ocorreram com vento entre 8 e 11 m/s, o que descarta falta de vento como causa. Trata-se de ruído do sensor de rotação com a turbina parada: sem giro para medir, o sinal oscila em torno de zero.

Tratamento: os valores negativos de generator_rpm, bem como eventuais rotações do rotor fora de 0 a 16 rpm, foram convertidos em nulo na tabela gold_fato_scada_curado, base das análises. A gold_fato_scada foi preservada sem alterações, mantendo a rastreabilidade do dado original, e a verificação após a curadoria confirmou a ausência de valores negativos.

Figura 20 – Auditoria de faixas de domínio com limites da ficha técnica do fabricante.



```

# faixas fisicamente plausíveis pra cada medida
# (turbina Servion IP02: 2050 kW nominal, corte ~3 m/s, ~25 m/s de parada)
chechagens = [
    # coluna,          mínimo, máximo, motivo
    ("power_kw",       -50, 2200, "potência: aceita pequeno negativo (consumo parada), teto acima do nominal"),
    ("wind_speed_m_s", 0, 30, "vento: nunca negativo; 30 m/s já é teto de acordo com manual"),
    ("rotor_speed_rpm", 0, 16, "rotor: gira devagar, -16 rpm nominal"),
    ("generator_rpm", 0, 1820, "gerador: milhares de rpm"),
    ("blade_pitch_deg", 0, 360, "ajuste da pá: ângulo em graus"),
    ("front_bearing_temp_c", -40, 150, "temperatura de mancal em operação"),
    ("gear_oil_temp_c", -40, 150, "temperatura normal do óleo"),
    ("nacelle_ambient_temp_c", -40, 45, "ambiente: faixa climática do Reino Unido com folga"),
]


for coluna, minimo, maximo, motivo in chechagens:
    fora = fato.filter(
        (F.col(coluna) < minimo) | (F.col(coluna) > maximo)
    ).count()
    print(f"{coluna:28s} fora de [{minimo}, {maximo}]: {fora:6d} # {motivo}")

```

power_kw fora de [-50, 2200]: 0 # potência: aceita pequeno negativo (consumo parada), teto acima do nominal
wind_speed_m_s fora de [0, 30]: 0 # vento: nunca negativo; 30 m/s já é tempestade extrema
rotor_speed_rpm fora de [0, 16]: 0 # rotor: gira devagar, -16 rpm nominal
generator_rpm fora de [0, 1820]: 2031 # gerador: milhares de rpm
blade_pitch_deg fora de [0, 360]: 0 # passo da pá: ângulo em graus
front_bearing_temp_c fora de [-40, 150]: 0 # temperatura de mancal em operação
gear_oil_temp_c fora de [-40, 150]: 0 # temperatura normal do óleo
nacelle_ambient_temp_c fora de [-40, 45]: 0 # ambiente: faixa climática do Reino Unido com folga

Fonte: elaborado pelo autor (2026).

Figura 21 – Investigação das leituras de rotação negativa do gerador.



```

print("generator_rpm negativos:", negativos.count(), "(esperado: 2031)")

# 2) esses negativos coincidem com turbina parada/sem gerar?
print(" ...com power_kw baixo (<10) ou nulo:",
      negativos.filter((F.col("power_kw") < 10) | F.col("power_kw").isNull()).count())

# 3) e coincidem com o status de parada (status_id = 1)?
print(" ...com status_id = 1 (Stop):",
      negativos.filter(F.col("status_id") == 1).count())

# 3) e coincidem com o status de parada (status_id = 1)?
print(" ...com rotor_speed_rpm = 0 (Stop):",
      negativos.filter(F.col("rotor_speed_rpm") < 0.5).count())

# 4) ver alguns pra sentir o padrão
display(negativos.select("generator_rpm", "rotor_speed_rpm", "power_kw", "wind_speed_m_s", "status_id")
         .orderBy("generator_rpm").limit(10))

```

generator_rpm negativos: 2031 (esperado: 2031)
...com power_kw baixo (<10) ou nulo: 2031
...com status_id = 1 (Stop): 421
...com rotor_speed_rpm = 0 (Stop): 2031

	1.2 generator_rpm	1.2 rotor_speed_rpm	1.2 power_kw	1.2 wind_speed_m_s	1.2 status_id
1	-589.2462158203125	0	-5.623089790344238	8.409375190734863	1
2	-582.386474609375	0	-1.51514005661010...	0.7113746404647827	1
3	-580.2172241210938	0	-7.789100170135498	5.151374816894531	1
4	-580.038330078125	0	-0.864270031452179	10.57906723022461	1
5	-291.37469482421875	0	-2.79020500183105...	10.505812649594896	1
6	-291.14044189453125	0	-1.179034948348999	11.269514083862305	1
7	-148.8850860595703	0	-3.766510009765625	9.250614166259766	1
8	-147.6631622314453	0	-2.723517656326294	11.139656066894531	1
9	-118.20106506347656	0	-3.74730396270751...	14.504249095916748	1
10	-99.30982208251953	0	-2.807988405227661	2.667250156402588	1

Fonte: elaborado pelo autor (2026).

5.5 Cobertura temporal

A análise do preenchimento mês a mês revelou uma queda uniforme em outubro de 2018, em todas as turbinas. Por corresponder também a uma das perguntas de negócio, o caso é apresentado na Seção 6.5.


6. Análise de Dados

As consultas foram escritas em SQL no notebook 05_analises, sobre a gold_fato_scada_curado e, para os eventos, sobre a silver_status. Em cada pergunta, apresentam-se o resultado obtido e sua interpretação para a operação do parque.

6.1 Pergunta 1 — Curva de potência

A potência média foi agregada por faixas de 0,5 m/s de velocidade do vento. A curva resultante (Figura 23) reproduz a curva de potência do fabricante: é praticamente nula abaixo de 3 m/s, cresce rapidamente até cerca de 12,5 m/s e se estabiliza próxima de 2.000 kW, próximo do valor nominal. A queda acima de 20 m/s reflete a atuação do controle em vento extremo e o pequeno número de leituras nessas faixas. A correspondência com a curva oficial valida o pipeline de ponta a ponta: após ingestão, tipagem, reconciliação e curadoria, os dados continuam representando corretamente a física da máquina.

Figura 22 – Query para curva de potência média do parque por faixa de vento.




```
%sql
SELECT
  floor(wind_speed_m_s * 2)/2 AS faixa_vento, --- agrupando de 0,5 em 0,5 m/s para facilitar a análise
  round(avg(power_kw),1) AS potencia_media_kw,
  count(*) AS n_leituras
FROM workspace.default.gold_fato_scada_curado
WHERE power_kw IS NOT NULL
AND wind_speed_m_s IS NOT NULL
GROUP BY floor(wind_speed_m_s * 2)/2
ORDER BY faixa_vento;
```

	1.2 faixa_vento	1.2 potencia_media_kw	2.3 n_leituras
1	0	-1	297
2	0.5	-1	1544
3	1	-1	3125
4	1.5	-1.5	5826
5	2	-1.1	10592
6	2.5	8.3	15812
7	3	40.6	16631
8	3.5	85.9	18567
9	4	138.4	21254
10	4.5	202.6	23250
11	5	282	24296
12	5.5	377.1	23774
13	6	493.4	21737
14	6.5	629.8	19883
15	7	786.7	18272

50 rows 1.749s runtime

Fonte: elaborado pelo autor (2026).

Figura 23 – Curva de potência média do parque por faixa de vento.




Fonte: elaborado pelo autor (2026).

Separando a curva por turbina (Figura 24), as seis coincidem na região de subida, mas se afastam em vento forte. Na faixa de 13 a 18 m/s (Figura 25), a turbina 5 entrega em média 1.674,7 kW, contra cerca de 2.006 kW das turbinas 2 e 4, uma perda de aproximadamente 16%. A amostra da turbina 5 (569 leituras) é da mesma ordem das demais (389 a 743), o que descarta a escassez de dados como explicação. A turbina 1 aparece levemente abaixo, com 1.924 kW.

A hipótese inicial de que a menor altura de cubo das turbinas 3 e 6 (68,5 m, contra 78,5 m das demais) reduziria a produção não se confirmou: ambas operam próximas das melhores. A causa da subperformance da turbina 5 é investigada nas Seções 6.2 e 6.3.

Figura 24 – Curvas de potência por turbina.



Fonte: elaborado pelo autor (2026).

Figura 25 – Potência média e número de leituras por turbina na faixa de 13 a 18 m/s.

	¹ ₂ turbina_id	^{1.2} potencia_media_kw	¹ ₃ n_leituras
1	5	1674.7	569
2	1	1924	711
3	6	1976.9	389
4	3	1981.4	638
5	4	2005.9	743
6	2	2006	735

6 rows 1.786s runtime Refreshed 12m ago


Fonte: elaborado pelo autor (2026).

6.2 Pergunta 2 — Disponibilidade

A fração do tempo em parada foi calculada, para cada turbina, sobre os 52.560 intervalos de 2018, a partir do status_id reconciliado. Todas as turbinas ficaram paradas entre cerca de 4,0% e 4,4% do tempo, com diferença inferior a meio ponto percentual entre a maior e a menor


(Figura 27). A turbina 5 está no grupo superior, mas em magnitude incapaz de explicar uma perda de 16% de produção. Portanto, sua menor geração não decorre de indisponibilidade, e sim de menor eficiência enquanto está em operação. O indicador considera apenas eventos do tipo Stop, escopo da reconciliação.

Figura 26 – Query para percentual do tempo em parada por turbina.



Fonte: elaborado pelo autor (2026).

Figura 27 – Percentual do tempo em parada por turbina.



Fonte: elaborado pelo autor (2026).

6.3 Pergunta 3 — Temperatura × operação e causa-raiz

Com base nas Perguntas 1 e 2, a causa da subperformance da turbina 5 foi investigada por eliminação de hipóteses, em três etapas.

Desgaste mecânico: em carga alta (potência acima de 1.500 kW), as temperaturas de mancais, gerador e óleo da multiplicadora são homogêneas entre as turbinas (Figura 28). A turbina 5 está entre as mais frias, com 30,3 °C no mancal do gerador, contra 31,3 °C a 32,6 °C das demais. Como atrito ou desgaste se manifestariam como sobreaquecimento, a hipótese foi descartada.

Faixa de captura: entre 6 e 10 m/s, abaixo da velocidade nominal, o ângulo de pitch, a rotação do rotor e a potência da turbina 5 são normais (Figura 29). O problema está, portanto, restrito ao vento forte.

Vento forte: entre 13 e 18 m/s, o ângulo médio de pitch da turbina 5 é de 24,86°, contra 12,36° a 13,78° das turbinas saudáveis, quase o dobro (Figura 30). Com as pás mais inclinadas, a turbina captura menos energia (BURTON et al., 2011): o rotor gira a 12,52 rpm, contra cerca de 14,9 rpm, e a potência cai para 1.674,7 kW.

A cadeia causal do ângulo de pitch excessivo, menor rotação e menor potência aponta como causa-raiz provável um controle de pitch descalibrado, que inclina as pás além do necessário em vento forte. Recomenda-se a inspeção e a recalibração do sistema de pitch da turbina 5 e o acompanhamento da turbina 1, cujo ângulo médio (15,83°) também está acima do grupo e é coerente com sua leve perda de produção.

Figura 28 – Temperaturas médias dos componentes em carga alta (potência > 1.500 kW).

	turbina_id	n_leituras	1.2 mancal_diant	1.2 mancal_tras	1.2 oleo_mult	1.2 mancal_gerador	1.2 ambiente
1	1	6689	74.3	68.3	51.8	31.3	9.2
2	2	7854	72.4	69.6	52	32.6	8.9
3	3	6244	74.4	68.5	51.6	32	8.2
4	4	6961	73.2	69	50.6	31.3	9
5	5	6053	73	67.8	50.5	30.3	8.2
6	6	4980	75.3	69.4	51.9	31.8	9.5

Fonte: elaborado pelo autor (2026).

Figura 29 – Pitch, potência e rotação por turbina na faixa de captura (6 a 10 m/s).

	1.2 turbina_id	1.2 n_leituras	1.2 pitch_medio	1.2 potencia_media	1.2 rotor_medio
1	1	19103	1.27	919.5	13.2
2	2	20604	0.87	957.6	13.41
3	3	18741	0.82	925.1	13.26
4	4	20068	1.4	916.2	13.19
5	5	17838	1.05	943.5	13.3
6	6	16801	1.31	899	13.09

6 rows 1.867s runtime

Fonte: elaborado pelo autor (2026).

Figura 30 – Pitch, potência e rotação por turbina em vento forte (13 a 18 m/s).



Fonte: elaborado pelo autor (2026).


6.4 Pergunta 4 — Eventos no tempo

Os eventos da `silver_status` foram analisados por frequência e por tempo total de duração, calculado a partir das janelas de início e fim (Figura 31). Em frequência, os eventos Informational dominam, com 68.608 registros (98,1% do total), mas são instantâneos: os 8.307 que possuem término somam apenas 431,7 horas, com duração média de 3,1 minutos.

Em tempo, o ranking se inverte. Os eventos Warning, menos numerosos que os Stop (524 contra 733), somam 6.776,4 horas, com duração média de cerca de 13 horas, contra 2.207,0 horas e cerca de 3 horas por evento dos Stop. Os eventos Communication são raros (98), mas os mais longos, com média de cerca de 19 horas.

O número de eventos, portanto, não indica onde está o tempo operacional comprometido: as turbinas passam cerca de três vezes mais horas sob Warning do que paradas. O resultado orienta a manutenção a priorizar a investigação desses alertas e reforça a expansão da reconciliação também para Warnings, hoje restrita aos eventos Stop.

Figura 31 – Eventos por status: frequência (acima) e horas totais e duração média (abaixo).



Fonte: elaborado pelo autor (2026).


6.5 Pergunta 5 — Qualidade e governança

A qualidade da base foi discutida na Seção 5: os nulos, cerca de 3,5%, correspondem a períodos de parada, e as leituras implausíveis se restringem à rotação negativa do gerador, tratada na camada curada. Não foram encontradas potências nem velocidades de vento fora das faixas definidas depois do tratamento.

Para a cobertura temporal, calculou-se o percentual de potência preenchida por turbina e por mês (Figura 32). O preenchimento fica em torno de 96% em quase todos os meses, exceto em outubro de 2018, quando as seis turbinas caem para 69,4%. A uniformidade entre máquinas independentes indica um evento sistêmico, como falha no sistema central de coleta ou parada geral do parque, e não falhas individuais, que produziriam percentuais diferentes entre as turbinas.

Conclui-se que a base é confiável para as análises propostas, com dois pontos de atenção identificados e documentados: o ruído do sensor de rotação do gerador e a lacuna sistêmica de outubro de 2018.

Figura 32 – Percentual de potência preenchida por turbina e por mês.



Fonte: elaborado pelo autor (2026).

6.6 Síntese

As respostas formam um diagnóstico encadeado. A reprodução da curva do fabricante validou o pipeline e localizou a turbina 5 como subperformante (Pergunta 1). A análise de disponibilidade mostrou que a perda não vem de paradas (Pergunta 2), e a eliminação da hipótese de desgaste, seguida da comparação do ângulo de pitch, apontou a causa-raiz provável (Pergunta 3).

A análise dos eventos indicou onde está o tempo operacional comprometido (Pergunta 4), e a auditoria de cobertura confirmou a confiabilidade da base, com as ressalvas documentadas (Pergunta 5). O cruzamento entre telemetria, eventos e cadastro, viabilizado pela camada analítica, levou de dados brutos a dados orientados à inteligência de negócio, fornecendo recomendação de manutenção concreta para o time de engenharia.

7. Autoavaliação

Considero que os objetivos definidos no início do trabalho foram atingidos. As cinco perguntas de negócio foram respondidas: a curva de potência foi reproduzida e a turbina subperformante identificada (P1); a disponibilidade foi medida, com a ressalva de considerar apenas eventos Stop (P2); a análise de temperatura e pitch chegou a uma causa-raiz provável, além do que a pergunta originalmente propunha (P3); os eventos foram caracterizados por frequência e duração (P4); e a qualidade da base foi auditada em completude, unicidade, domínio e cobertura (P5).

As principais dificuldades estiveram no formato dos dados brutos e nas limitações da plataforma. A Free Edition não permite acesso à internet a partir dos notebooks, o que exigiu o upload manual dos arquivos. Os CSVs pediram tratamentos específicos: linhas de metadados antes do cabeçalho, identificador da turbina apenas no nome do arquivo, marcador BOM e o caractere “-” em campos de data, que interrompia a conversão até a adoção do `try_cast`. No SQL, o uso de funções de janela sobre agregações exigiu reescrever consultas com subconsultas.

A dificuldade mais instrutiva foi a definição das faixas de validade. As faixas iniciais, estimadas sem o manual da turbina, geraram alertas falsos e deixaram passar valores inválidos. Ao substituí-las pelos dados da ficha técnica do fabricante e compreender a convenção circular do ângulo de pitch, a auditoria passou a discernir o comportamento real da máquina. Nesse ponto, a formação em engenharia mecânica foi decisiva para interpretar os sinais, o que é natural, pois em um projeto real, o engenheiro de dados deve consultar o especialista de negócio

para orientar tomadas de decisões no processo da modelagem, sobretudo qualidade e governança.

Considero o trabalho muito produtivo para explorar bibliotecas como pandas e PySpark e, principalmente, a linguagem SQL. A imersão no Databricks também me aproximou da engenharia de dados com uma abordagem mais profissional, sem perder a didática. Sobretudo, o projeto permitiu aplicar na prática boas práticas de extração, carga, transformação, curadoria e análise de dados, abrangendo tanto aspectos técnicos da engenharia de dados quanto de inteligência de negócio. Ficou claro que um grande volume de dados brutos, que à primeira vista parece ter pouco valor, pode sustentar decisões mais bem embasadas depois de lapidado pelo time de dados.

Como trabalhos futuros, proponho incluir os eventos Warning e Communication na reconciliação, com regra de prioridade entre eventos sobrepostos; estender o pipeline aos anos seguintes; investigar a causa da lacuna de outubro de 2018; comparar a potência real com as estimativas de potência teórica disponíveis no SCADA; e desenvolver um modelo preditivo de falhas do sistema de pitch a partir da camada Gold utilizando técnicas de Machine Learning.

Referências

- A SHORT-TERM wind power forecasting approach based on model configuration optimization via prequential-cross cooperative validation estimation. **Sustainability**, Basel, v. 17, n. 22, art. 9929, 2025. Disponível em: <https://www.mdpi.com/2071-1050/17/22/9929>. Acesso em: 25 set. 2026.
- ARMBRUST, M. et al. Delta Lake: high-performance ACID table storage over cloud object stores. **Proceedings of the VLDB Endowment**, [S. l.], v. 13, n. 12, p. 3411-3424, 2020.
- ARMBRUST, M. et al. Lakehouse: a new generation of open platforms that unify data warehousing and advanced analytics. In: CONFERENCE ON INNOVATIVE DATA SYSTEMS RESEARCH, 11., 2021, [S. l.]. **Proceedings** [...]. [S. l.]: CIDR, 2021.
- BLUE ENERGY. **Kelmarsh**. [S. l.]: Blue Energy, [20--]. Disponível em: <https://blue-energyco.com/our-projects/kelmarsh>. Acesso em: 25 set. 2026.
- BURTON, T. et al. **Wind energy handbook**. 2. ed. Chichester: John Wiley & Sons, 2011.
- DAMA INTERNATIONAL. **DAMA-DMBOK**: data management body of knowledge. 2. ed. Basking Ridge: Technics Publications, 2017.
- DATABRICKS. **Databricks documentation**. [S. l.]: Databricks, 2026. Disponível em: <https://docs.databricks.com>. Acesso em: 26 set. 2026.
- KIMBALL, R.; ROSS, M. **The data warehouse toolkit**: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.
- KLEPPMANN, M. **Designing data-intensive applications**. Sebastopol: O'Reilly Media, 2017.
- PLUMLEY, C. **Kelmarsh wind farm data**. [S. l.]: Zenodo, 2022. Conjunto de dados. DOI: 10.5281/zenodo.5841834. Disponível em: <https://doi.org/10.5281/zenodo.5841834>. Acesso em: 23 ago. 2026.
- REIS, J.; HOUSLEY, M. **Fundamentals of data engineering**: plan and build robust data systems. Sebastopol: O'Reilly Media, 2022.
- SENVION. **Senvion MM92**: technical data. [S. l.]: Senvion, [20--]. Ficha técnica.
- ZAHARIA, M. et al. Apache Spark: a unified engine for big data processing. **Communications of the ACM**, New York, v. 59, n. 11, p. 56-65, 2016.